

Anteproyecto

DIEGO JOSÉ ORELLANA BOJORQUEZ

Universidad Rafael Landívar
djorellanab@outlook.com

9 de agosto de 2019

Resumen

*En la presente publicación se presenta los detalles para realizar el proyecto de graduación, **Análisis de la Interfaz de Programación de Aplicaciones (API) del dispositivo Kinect V2 para la detección de los pasos de un movimiento.***

***Descriptores:** Kinect V2, Sedentarismo, Reconocimiento de movimiento Y Seguimiento de esqueleto*

I. INTRODUCCIÓN

El sedentarismo es un modo de vida orientado al poco ejercicio que realizan una persona, además de ser una de las causas de enfermedades no transmisibles, como la diabetes. Por lo tanto, en la presente publicación se presenta el detalle del proyecto final de Ingeniería en informática y sistemas, la cual consta de realizar un prototipo que reconozca un movimiento, además de realizar una evaluación de la actividad de física de una persona a partir del conteo de repeticiones del movimiento.

II. JUSTIFICACIÓN

El sedentarismo es una de las principales causas de la obesidad y sobrepeso en Guatemala, así mismo constituye un factor determinante para el desarrollo de enfermedades crónicas no transmisibles, concretamente la diabetes, tal como se muestra en el estudio médico, Risk to Develop Type 2 Diabetes Mellitus according to FINDRISC tool in Guatemalan Physicians aged 40-60 years (Castro y cols., 2017), menciona que el 47 % de los guatemaltecos con diabetes tiene problemas de obesidad y el 31 % sufren de problemas de sobrepeso, por lo cual refleja la inactividad física en una gran parte de la población guatemalteca.

Por otra parte, se ha reducido el nivel de actividad física en las personas guatemaltecas, tal como se menciona en la encuesta de diabetes, hipertensión y factores de riesgo de enfermedades crónicas (Orellana, Ramírez, Barceló, y Gil, 2006), el 27.68 % de los guatemaltecos presenta sedentarismo, debido que no realiza actividades físicas o lo hacen por menos de 30 minutos.

Igualmente, se realizó un estudio a 392 niños y adolescentes en escuelas rurales y urbanas de Guatemala (Orellana y cols., 2006), en donde indica que alrededor del 62 % de los niños del área urbana presenta problemas de sobrepeso y un 13.8 % de obesidad, de modo que los autores concluyeron que el sobrepeso y la obesidad coexisten en los niños y adolescentes guatemaltecos.

En resumen, el presente proyecto brindará una solución innovadora y tecnológica para evaluar la actividad física en los guatemaltecos, a partir de la detección de los pasos para realizar una movimiento. De tal modo de responder la siguiente pregunta:

¿Será posible contabilizar el sedentarismo de una persona, a partir de la actividad física de un movimiento?

III. ESTUDIOS RELACIONADOS

I. Sistema de detección y reconocimiento de la postura corporal basado en Kinect

Pisharady y Saerbeck (2013) mencionan que alrededor del 66 % de la población mundial utilizan la comunicación no verbal, dicha comunicación esta conformado por posturas corporales, gestos, expresiones faciales y movimientos corporales. Por lo tanto, los autores propone un sistema para detectar expresiones estáticas -i.e. Posiciones que no cambian durante un período de expresión-.

Dicho sistema detecta y reconoce posturas corporales de una persona con la ayuda del sensor del Kinect, ya que le proporciona la posición de las articulaciones del cuerpo humano -e.g. mano, codo, hombro, rodilla- en un espacio vectorial definido por el sensor. Posteriormente se calcula las características angulares respecto a dos vectores de articulaciones, por ejemplo; para encontrar la característica angular del codo derecho se utiliza los vectores de la mano derecha y hombro derecho.

Por otro lado, Pisharady y Saerbeck (2013) analizaron un total de 11 componentes angulares para entrenar una máquina de soporte vectorial -i.e SVM- de núcleo polinómico, con la finalidad de detectar un total de 10 movimientos estáticos -e.g. Pararse, agacharse, hablar por teléfono-, así mismo el entrenamiento consistió en tomar 6000 muestras de posturas de 6 personas diferentes -i.e. Cada persona realizó 100 muestras por postura-.

Finalmente, Pisharady y Saerbeck (2013) recolectaron un total de 5000 muestras positivas -i.e. Correspondiente a los 10 movimientos estáticos-. Como resultados obtuvieron una falla de pronóstico de 1.46 %, debido que el sensor Kinect no podría rastrear correctamente el seguimiento esqueleto.

II. Reconstrucción de posturas en tiempo real

H. P. Shum, Ho, Jiang, y Takagi (2013) determinaron que el sensor Kinect tiene un problema con el reconocimiento de postura a la hora de interactuar con objetos externos -e.g. Baloncesto, levantamiento pesas-, por lo tanto, algunos datos de seguimiento de esqueleto son incorrecto, de tal manera que lo autores propone un método para medir la confiabilidad de datos al momento de detectar una postura.

Para determinar el nivel de confiabilidad de datos, H. P. Shum y cols. (2013), contruyeron una base de datos de 21590 posturas estáticas, la cual mide los ángulos entre articulaciones. Esto permite extraer las 30 posturas que se asemeja al movimiento real -i.e. 30 vecinos más cercanos-. Posteriormente, localizan cada postura en un nuevo espacio vectorial -i.e Espacio diferente al Kinect-, seleccionando así la postura que tenga uno menor distancia entre los puntos vectoriales.

Finalmente, H. P. Shum y cols. (2013), realizaron las pruebas a 27 personas, dichas pruebas consistía en hacer actividades con objetos externos -e.g. caja, silla, lápiz, pelota-, analizando la parte superior -i.e. Arriba de la caderas- e inferior de cada persona. Como resultados a estas pruebas, encontraron una diferencia de distancia -i.e. Entre la postura real y de referencia- de 9 a 13 cm, determinando así un nivel de confiabilidad del de 80 % respecto a dos sistemas de detección de movimiento en tiempo real (H. P. Shum, Komura, y Takagi, 2011; H. Shum y Ho, 2012).

III. Detección de posturas a la hora de sentarse para prevenir el síndrome de los trabajadores de oficina usando el Kinect

Paliyawan, Nukoolkit, y Mongkolnam (2014) estudiaron el síndrome del trabajador de oficina, la cual consiste en un grupo de síntomas que tiene los trabajadores por los hábitos no saludables -e.g. La postura a la hora de sentarse-,

provocando en la persona distintos dolores corporales -e.g. Muscular, sequedad en los ojos-.

En relación a los riesgos de salud de una persona, Paliyawan y cols. (2014), investigaron que una de las causas de las enfermedades no transmisibles es debido al tiempo prolongado de estar sentado, sin realizar ninguna actividad física. Por lo tanto, los autores proponen un sistema que detecta las posturas a la hora que esta trabajando en una oficina.

Para realizar dicho sistema, Paliyawan y cols. (2014) estudiaron las posturas de 28 personas, recolectaron un total de 1326 posturas. De igual manera, cada postura contenía un total 31 atributos -i.e. Tiempo y posición de 10 articulaciones-. Posteriormente, el sistema procesa los datos y encuentra la distancia euclidiana entre los datos consecutivos, permitiendo normalizar las distancias máximas y mínimas por persona y en forma general -i.e. Conjunto de personas analizadas-.

Finalmente, el sistema detecta una buena o mala posición, a partir de cuatro métodos de clasificación: Árboles de decisiones, redes neuronales, clasificador bayesiano y 5 vecinos más cercanos. Por lo tanto, para seleccionar el mejor método, los autores realizaron una prueba a 10 personas, de tal manera que el mejor clasificador es de los vecinos más cercano, debido que tuvo una precisión de 98.83 %.

iv. Una comparación entre las técnicas heurísticas y de aprendizaje automático en la detección de caídas con Kinect v2

En la publicación, A Comparison Between Heuristic And Machine Learning Techniques In Fall Detection Using Kinect v2 (Amini, Bannitsas, y Cosmas, 2016), se compara 2 métodos para detectar la posición, velocidad y aceleración de un usuario al momento de que un usuario sufre de una caída.

Según Amini y cols. (2016), el primer método se basa en la heurística que aprovecha la funcionalidad del seguimiento de esqueleto, la

cual consiste en analizar la distancia entre la articulación de la cabeza y el suelo -i.e. Recta respecto a las articulaciones de los pies-, mientras que el segundo método consiste en una máquina de aprendizaje, usando la funcionalidad visual y constructor de gestos -i.e. VGB-, la cual analiza el escenario y le asigna un color -i.e. en escala RGB- a las posibles fallas de caídas.

Así mismo, Amini y cols. (2016) mencionan que para el primer método los datos se fueron determinando a partir de la ecuación escalar de un plano, mientras que en el segundo método se utilizó el algoritmo AdaBoostTrigger -i.e. Modelo discreto de VGB-.

Finalmente, Amini y cols. (2016) realizaron una prueba con 11 personas, la cual concluyeron que para el primer método detectaba un 95.42 % de las caídas, mientras que para el segundo método fue de 88.33 %, por lo tanto el primer método era más exacto debido que no dependía tanto de los datos de entrenamiento -i.e. El usuario no replicaba los vídeos de entrenamiento del modelo VGB-.

IV. OBJETIVOS

I. General

Implementar un modelo de pronóstico de detección de los pasos que debe seguir para realizar un movimiento, con la ayuda de las herramientas proporcionada por la interfaz de programación de aplicaciones del dispositivo Kinect V2.

II. Específicos

- Definir el movimiento a analizar, considerando los pasos que se debe seguir para realizar dicho movimiento.
- Desarrollar una rutina del movimiento, para la captura de datos.
- Identificar la distancia mínima y máxima de profundidad entre el Kinect y el usuario para la detección del seguimiento de esqueleto.

- Recolectar los datos de la rutina del movimiento, a partir de la herramienta Kinect Studio.
- Crear una base de datos de reconocimiento de gesturas y posturas, por medio de la herramienta Visual Gesture Builder y los datos recolectado del Kinect Studio.
- Calcular los errores del pronóstico del reconocimiento de gesturas y posturas.
- Crear una interfaz gráfica que detecte las repeticiones realizada del movimiento.
- Crear una interfaz gráfica que demuestre los resultados de un entrenamiento.
- Comprobar el modelo de reconocimiento de gesturas y posturas del movimiento.

V. HIPÓTESIS

Un software que mida el sedentarismo a partir de la actividad física de una persona.

VI. METODOLOGÍA

Para el presente proyecto se debe seleccionar un movimiento, describiendo todos los pasos respectivo del movimiento, además de las articulaciones que interviene para realizar el movimiento, por ejemplo: Air Squat:

Cuadro 1: *Análisis del movimiento*

Air Squat	
Joints	Rodilla derecha e izquierda Tobillo derecho e izquierdo cadera derecha e izquierda Espalda
Paso	Descripción
1	Párese con los pies ligeramente más separados que el ancho de los hombros, manteniendo el peso sobre los talones y los pies inclinados ligeramente hacia afuera.
2	Coloque sus brazos frente a su pecho en una posición cómoda. Empieza a doblar las rodillas para bajar hacia el suelo. Su espalda debe permanecer recta.
3	Continúa doblando las rodillas hasta que los muslos estén paralelos al suelo.

Fuente: withfit (2019)

Posteriormente a la definición del movimiento, se debe crear una rutina del ejercicios tomando en cuenta los factores que puede llegar a intervenir -e.g. Estiramiento, Calentamiento, Práctica del movimiento-, permitiendo simular el ambiente de una rutina, tal como se muestra el siguiente ejemplo:

Cuadro 2: *Ejemplo de Rutina de ejercicio*

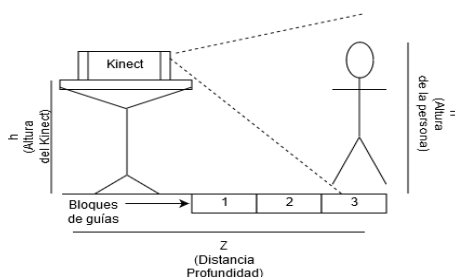
Rutina de Air Squat	
Tiempo	2 minutos
Trabajo	Realizar las máximas repeticiones posibles de Air Squat durante el tiempo asignado.

Fuente: Autor del anteproyecto

Una vez definido la rutina del movimiento, se debe encontrar la distancia de profundidad entre el usuario y el Kinect, en donde se genere correctamente el seguimiento de esqueleto del usuario al momento de realizar el movimiento,

tal como se observa en la siguiente figura.

Figura 1: Visualización de captura de datos



Fuente: Elaboración propia

En la figura 1, se observa las siguientes variables:

- **La altura del kinect respecto el suelo:** esta variable permanecerá constante por movimiento.
- **La altura del usuario:** Se calculará respecto la posición de altura de las articulaciones: Cabeza y pies del usuario.
- **Distancia entre el usuario y Kinect:** Distancia de profundidad respecto el Kinect y el punto de articulación de análisis - e.g. Centro de cadera, Centro de hombro, Espalda-.
- **Bloques guías:** Enumeración de rangos de profundidad para realizar el movimiento.

Cuadro 3: Ejemplo de bloques guías

bloque	inferior	superior
1	0 cm	60 cm
2	60 cm	120 cm
3	120 cm	180 cm
4	180 cm	240 cm
5	240 cm	300 cm
6	300 cm	360 cm

Una vez finalizado la toma de datos de distancia de profundidad, se realizará una tabla de frecuencia, para determinar la distancia mínima y máxima para realizar el movimiento correspondiente:

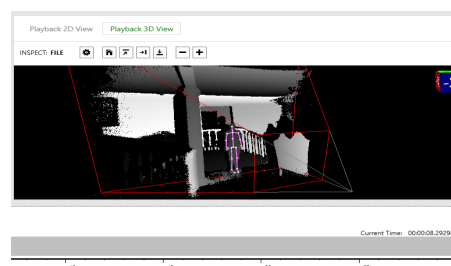
Cuadro 4: Ejemplo de tablas de frecuencias

Articulación	Centro de los hombros	
bloque	altura	frecuencia
1	0 cm	0
2	0 cm	0
3	0 cm	0
4	0 cm	0
5	120 cm a 160 cm	20
6	160 cm a 200 cm	10

Tal como se observa en el ejemplo de tabla de frecuencia, se puede determinar que el seguimiento de esqueleto del movimiento se genera correctamente a una distancia mínima de 240 cm hasta una distancia máxima de 360 cm -i.e. Entre los bloques guías 5 y 6-.

Luego de encontrar las distancia de profundidad, se posicionará la persona y se grabará un vídeo realizando la rutina del movimiento, a partir de la herramienta Microsoft Kinect Studio:

Figura 2: Ejemplo de vídeo del Kinect Studio



Fuente: Tomado por el autor

Terminando la recolección de datos de vídeo, se le asignará una etiqueta a cada paso correspondiente del movimiento, dicha etiqueta tendrá un valor entre 0 a 1 -i.e. Valor pronóstico-, tal como se observa en la siguiente tabla:

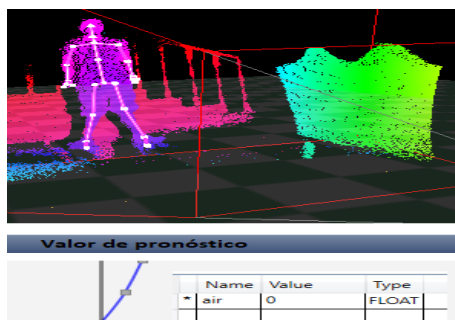
Cuadro 5: Etiquetas de ejemplo

Air Squat	
Pasos	3
Offset	$1/(3-1) = 0.5$
Paso	Etiqueta
1	0.0
2	0.5
3	1.0

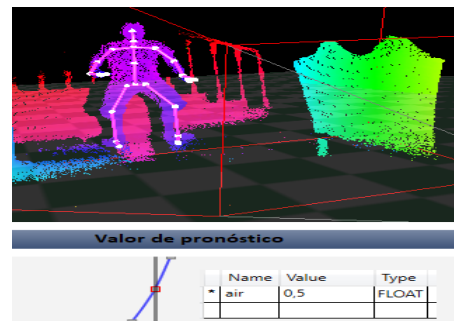
Fuente: Autor del anteproyecto

Esta tabla es un ejemplo que permite asignarle etiquetas al modelo de pronóstico para la detección del paso del movimiento -e.g. Cuando el valor es cercano a 0, se reconoce el paso 1-, tomando en cuenta las variables de: distancias, velocidades y aceleraciones de cada articulación capturado en el seguimiento de esqueleto.


Para realizar el modelo de pronóstico de detección de paso del movimiento, se creará una base de datos de reconocimientos de gesturas y posturas, con la herramienta Visual Gesture Builder, la cual se analizará los vídeos generado por el Kinect Studio, y se le asignará el valor de la etiqueta del paso, en el momento del vídeo que se esta realizando, tal como se muestra en las siguientes figuras:

Figura 3: Asignación paso 1

Fuente: Tomado por el autor


Figura 4: Asignación paso 2

Fuente: Tomado por el autor

Figura 5: Asignación paso 3

Fuente: Tomado por el autor

Concluyendo con la asignación de etiquetas de cada vídeo, se utilizará cierta cantidad de datos para el entrenamiento y compilación de la base de datos de gesturas y posiciones del movimiento. Y así mismo los datos que sobran -i.e. Datos de pruebas- será utilizado por la herramienta de análisis de Visual Gesture Builder, que proporcionará el valor de pronóstico y el valor esperado:

Figura 6: Resultado de Gesturas

Fuente: Tomado por el autor

En la figura de resultados de gesturas, se observa que el valor esperado es de 0.000000, mientras que el valor de pronóstico es de -23843×10^{-6} , por lo tanto se va a tabular los valores esperados y pronosticado por cada frame de cada vídeo de prueba, y a partir de estos valores se determinará los siguientes errores del pronóstico:

Y_t	Esperado
Y'_t	Pronosticado
e_t	$Y_t - Y'_t$
t	id
n	TotalDeDatos

■ **Error medio del pronóstico (EMP)**

$$EMP = \frac{\sum_{t=1}^n e_t}{n}$$

■ **Error medio al cuadrado (EMC)**

$$EMC = \frac{\sum_{t=1}^n (e_t)^2}{n}$$

■ **Desviación estándar de los errores (DDE)**

$$DDE = \sqrt{\frac{\sum_{t=1}^n (e_t - EMP)^2}{n - 1}}$$

■ **Desviación absoluta de la media (DAM)**

$$DAM = \frac{\sum_{t=1}^n |e_t|}{n}$$

■ **Porcentaje de error medio absoluto (PEMA)**

$$PEMA = \frac{\sum_{t=1}^n \left| \frac{e_t}{Y_t} \right| * 100}{n}$$

De igual manera, es necesario probar distintos modelos de pronóstico de gesturas y posiciones de un movimiento para identificar el modelo que tenga un menor error, por lo tanto se utilizará la técnica de cross validation:

Cuadro 6: Ejemplo de cross validation

Folds	1	2	3	4
Datos	25 %	25 %	25 %	25 %
#	Folds build			Fold Test
1	1	2	3	4
2	1	2	4	3
3	1	3	4	2
4	2	3	4	1

En la tabla de ejemplo de cross validation, se separa en 4 Folds, la cual cada Fold contiene el 25 % de los datos capturados, de igual manera se divide en 4 modelos de pronóstico de gesturas y posiciones, por cada modelo se utilizará el 75 % de los datos para construirlo y el 25 % de pruebas, así mismo se debe calcular los respectivos errores de pronóstico:

Cuadro 7: Ejemplo de errores calculado en cross validation

#	EMP	EMC	DEE	DAM	PEMA
1	2.60	230	11.7	8.40	12.0 %
2	1.00	180	8.4	7.30	9.4 %
3	-4.10	240	10.5	7.90	11.0 %
4	-2.00	260	12.3	9.97	13.4 %

Para el presente ejemplo se seleccionará el modelo 2, debido que contiene un menor error comparado con los demás modelos, así mismo se puede determinar la información necesaria para reconocer el movimiento:

E	Etiqueta
off	Offset
err	Error

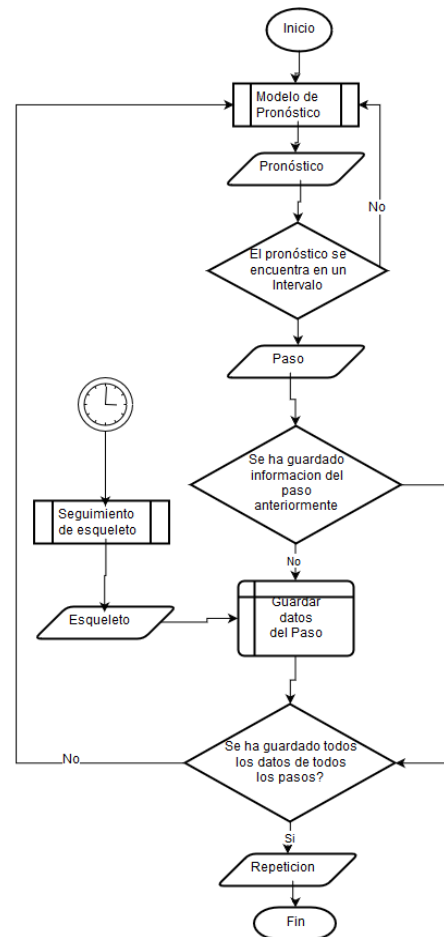
$$min(E) = \begin{cases} E & \text{Primera E} \\ E - (of * er / 2) & \text{E's del medio} \\ E - (of * er) & \text{Ultima E} \end{cases}$$

$$\max(E) = \begin{cases} E + (of * er) & \text{Primera E} \\ E + (of * er / 2) & \text{E's del medio} \\ E & \text{Ultima E} \end{cases}$$

Cuadro 8: Ejemplo de metadata del movimiento

Nombre	Air Squat		
Pasos	3		
Joints	Tobillo derecho, Tobillo izquierdo Rodilla derecha Rodilla izquierda Cadera derecha Cadera izquierda Espalda		
Articulación de análisis	Centro de los hombros		
Profundidad Mínima	240 cm		
Profundidad Máxima	360 cm		
off	0.5		
Modelo	2		
err	9.4 %		
Paso	E	Min	Max
1	0	0	0.0470
2	0.5	0.4765	0.5235
3	1	0.9530	1.0000

Tal como se observar en la tabla, si la probabilidad de pronóstico se encuentra en el intervalo de 0 a 0.0470, va reconocer el paso 1, de igual manera es necesario reconocer las repeticiones del movimiento por lo cual debe seguir el siguiente algoritmo:

Figura 7: Algoritmo reconocimiento de repeticion

Fuente: realizado por el autor

Tal como se observar en el algoritmo, se va a reconocer una repetición, siempre cuando el usuario haya pasado por todos los pasos correspondiente del movimiento, Así mismo por cada paso se va almacenar datos del esqueleto:

ID Repeticion : Entero
 SE Serie : Entero
 S Paso : Entero
 p probabilidad : Decimal
 A Articulacion : Entero
 T Tiempo(Segs) : Decimal
 x Ancho(Pixeles) : Decimal
 y Altura(Pixeles) : Decimal

Una vez identificado las repeticiones y los datos que se va almacenar, será necesario realizar

una interfaz gráfica, en donde permita detectar los pasos del movimiento y las repeticiones que realiza en un período de tiempo:

Figura 8: Interfaz gráfica de reconocimiento de movimiento



Fuente: Tomado por el autor

La interfaz gráfica será implementada en Windows Presentation Foundation -i.e. WPF-. En dicha interfaz se debe adjuntar la base de datos de Gesturas, realizada por el Visual Gesture Builder, y la información extra del movimiento -i.e. Archivo de metadata en formato JSON-. Además de indicar los parámetros de la rutina del ejercicio -i.e. Tabata-: Tiempo de trabajo, Tiempo de descanso y la cantidad de series.


Teniendo todos estos parámetros de configuración, el usuario puede empezar la rutina en la distancia de profundidad recomendada -i.e. Para el presente ejemplo sería una distancia de 240 a 360 cm-, la cual se le mostrará en tiempo real la imagen del seguimiento de esqueleto -i.e. Imagen en 2 Dimensiones-, Así mismo el usuario debe realizar las máximas repeticiones posibles durante el tiempo de trabajo. Una vez finalizado la rutina, se exportará un archivo con los siguientes resultados:

- Tiempo de descanso
- Tiempo de trabajo
- Cantidad de series
- Volumen de repeticiones
- Duración total de la rutina
- Repeticiones máxima durante un período de tiempo mínimo
- Repeticiones promedio por serie

- Tiempo promedio por repetición
- Tiempo promedio entre dos pasos seguidos.
- Flexibilidad promedio de cada articulación por cada paso.
- Distancia promedio de cada articulación entre dos pasos seguidos.

Finalmente se debe crear una interfaz gráfica que muestre todos los resultados respectivos de la rutina de una manera visual:

Figura 9: Ejemplo de tabata de Air Squat



Fuente: Realizado por el autor

En el ejemplo visual de Tabata, mide la actividad física de una persona, a partir de repeticiones del movimiento, Air Squat. Se debe tomar en cuenta que la rutina de ejemplo se configuró 4 series de 60 segundos de trabajo y 60 segundos de descanso, realizando un total de 36 repeticiones durante 480 segundos.

Finalmente para comprobar el modelo de reconocimiento de gesturas y posturas del movimiento, se realizará un conjunto de evaluaciones -i.e. Todas las evaluaciones tendrá configurada los mismos parámetros-.

Así mismo en cada evaluación, habrá una persona contando las repeticiones respectivas por series y finalmente se va a comparar contra las repeticiones del software, tal como se observa en las siguiente tabla:

Cuadro 9: Ejemplo de validación de movimiento

Air Squat	
Repeticiones esperada	Repeticiones Pronosticada
10	10
9	8
11	12

Fuente: Autor del anteproyecto

El motivo de esta tabulación de datos, es para encontrar el error de detección de repetición del movimiento -i.e. Desviación estándar-.

VII. RECURSOS

I. Tecnológicos

- Sensor Kinect Xbox One -i.e. V2-.
- Adaptador del sensor Kinect.
- Kinect SDK V2
- Computadora -i.e. Procesamiento, almacenamiento y memoria suficiente para ejecutar el Kinect SDK V2-.

II. Educativos

- IDE: Licenciamiento de Visual Studio professional
- IDE: Visual Studio Code
- Github Education
- Licenciamiento de Visual Studio professional

III. Humanos

- Departamento de deportes de la Universidad Rafael Landívar

VIII. VALIDACIONES

mundial de la salud (2019b), define actividad sedentaria como una actividad que no realiza la actividad física, así mismo se considera actividad física a cualquier movimiento corporal producido por los músculos esqueléticos que exija gasto de energía (mundial de la salud,

2019a). De igual manera el gasto de energía se presenta al momento de que un músculo se contrae, ya que se liberan moléculas llamadas, Adenosín Trifosfato -i.e. ATP-, dicha molécula se puede metabolizar de tres formas distintas (Marieb, 2008, p. 195):

1. **Fosforilación directa:** Al momento de realizar una actividad intensa -e.g. Corrida de 100 mts, durante un período de 15 segundos-.
2. **Respiración aeróbica:** Al momento que los músculos se encuentra en reposo o realiza un ejercicio leve -i.e. Cuando una persona mira la televisión-.
3. **Glucólisis anaeróbico y formación de ácido láctico:** Al momento que los músculos realiza una actividad moderada -i.e. Cuando una persona realiza repeticiones de sentadillas durante un período de 1 a 2 minuto-.

Tal como se observa, las moléculas de energía se metabolizan al momento de realizar una actividad física, dicha actividad puede ser programados a partir de rutinas, como por ejemplo el Tabata -i.e. Rutina de ejercicio de alta intensidad-, la cual consta de un entrenamiento de series de tiempo de descanso y de trabajo, en donde la persona debe hacer las máxima cantidad de repeticiones posible de un movimiento durante el tiempo de trabajo. Por lo tanto esta rutina puede llegar a producir grandes cantidades de moléculas de energía, ya que en el año 1996, el japonés científico, Izumi Tabata, comparó una rutina intensa de 4 minutos contra una rutina tradicional de 60 minutos, por medio del volumen de oxígeno que puede procesar el cuerpo humano. En donde observó que para la rutina tradicional la persona puede llegar a consumir un 70 % de oxígeno mientras que en la rutina intensa llegó a consumir hasta un 170 % de oxígeno, por lo tanto Izumi Tabata concluyó que el atleta puede tener un mejor metabolismo -i.e. Producción y consumo de energía-, al momento de realizar una rutina de alta intensidad (Emberts, Porcari, Doherty, Steffen, y Foster, 2013).

El presente proyecto se va a validar la contabilización del sedentarismo a partir del volumen de repeticiones que ha realizado una persona, tal como se muestra en la siguiente tabla:

Cuadro 10: Ejemplo Validación de repeticiones

Movimiento	Air Squat
Tiempo de descanso	20
Tiempo de trabajo	30
Series	2
Volumen de repeticiones	
Fecha	26/07/2017
	17

Se debe tomar en cuenta que el presente proyecto es un software que le brindará un archivo de resultados -i.e. Formato Json- que cuantifica la cantidad de repeticiones de un movimiento, a partir de los parámetros respectivo de la rutina Tabata, sin embargo cada entidad -i.e. Usuario del sistema- debe ser responsable del almacenamiento del archivo de resultados, para llevar el registro de evaluaciones de sus usuarios, tal como se muestra en las siguiente tabla:

Cuadro 11: Ejemplo de Registros histórico de evaluaciones

Movimiento	Air Squat
Entidad	Deportes de la URL
Persona	Diego Orellana
Tiempo de descanso	20
Tiempo de trabajo	30
Series	2
Volumen de repeticiones	
Fecha	26/07/2017
	17
	26/08/2017
	16
	26/09/2017
	19
	26/10/2017
	19

En la tabla de ejemplo se puede observar que el departamento de deportes de la URL

lleva el registro históricos de evaluaciones del usuario Diego Orellana, permitiendo evaluar el sedentarismo de dicho usuario, debido que en los resultados se puede contemplar el aumento de su sedentarismo durante su segunda evaluación, ya que realizó una menor cantidad de repeticiones -i.e. Produce menor cantidad de energía-, mientras que en la tercera y cuarta evaluación disminuyó su sedentarismo porque realizó una repetición más con respecto a su primera evaluación.

IX. CONCLUSIONES

- Se ha concluido que para analizar el movimiento, es necesario separarla por pasos, así mismo es preciso definir las articulaciones del cuerpo que interviene en el movimiento.
- Se ha concluido que la rutina del movimiento es un estándar para la captura de datos, la cual permite organizar y ordenar los datos del seguimiento del esqueleto.
- Se ha concluido que la altura del usuario y la altura del Kinect afecta la distancia mínima y máxima de profundidad para la detección del seguimiento del esqueleto.
- Se ha concluido que es necesario recolectar los datos del seguimiento de esqueleto de distintas personas debido que genera distintas velocidades y aceleraciones al momento de ejecutar el movimiento.
- Se ha concluido que es necesario recolectar los datos del seguimiento de esqueleto de distintas personas debido que genera distintas velocidades y aceleraciones al momento de ejecutar el movimiento.
- Se ha concluido que para la creación de reconocimiento de gesturas y posturas es necesario asignarle una etiqueta a cada paso del movimiento. Así mismo el proceso de asignación de etiqueta ocurre en el momento que el usuario esta empezando a realizar el paso del movimiento.
- Se ha concluido que para calcular los errores del pronóstico será necesario realizar distintas bases de datos de reconocimientos de gesturas y posturas, a partir de la

técnica cross validation, la cual separa un porcentaje de construcción del modelo de reconocimiento y otro porcentaje de datos para probar el modelo.

- Se ha concluido que dentro de la interfaz gráfica de detección de repeticiones del movimiento y la configuración de la rutina tabata, es necesario la base de datos de gesturas y la metadata respectiva del movimiento.
- Se ha concluido que la interfaz gráfica de resultado de la rutina tabata, muestra la cantidades de repeticiones del movimiento respecto a las series de tiempo de trabajo.
- Se ha concluido que para la validación del modelo de reconocimiento de gesturas y posturas del movimiento, es necesario que el investigador realice el conteo de repeticiones por serie y posteriormente compararlo con los resultados de la máquina.

REFERENCIAS

- Amini, A., Banitsas, K., y Cosmas, J. (2016). A comparison between heuristic and machine learning techniques in fall detection using kinect v2. En *2016 IEEE International Symposium on Medical Measurements and Applications (MMEA)* (pp. 1–6).
- Castro, E. D., Velásquez, G. A., Santos, E. L., Oliva, G. A., Chang, C. E., y Soto, H. F. (2017). Risk to develop type 2 diabetes mellitus according to findrisc tool in guatemalan physicians aged 40–60 years. *International Journal of Medical Students*, 5(1), 20–25.
- Emberts, T., Porcari, J., Doherty, S., Steffen, J., y Foster, C. (2013). Exercise intensity and energy expenditure of a tabata workout. *Journal of sports science & medicine*, 12(3), 612.
- Marieb, E. N. (2008). *Anatomía y fisiología humana* (n.º Sirsi) i9788478290949). Pearson Educación.
- mundial de la salud, O. (2019a). *Estrategia mundial sobre régimen alimentario, actividad física y salud*. Descargado 2019-07-16, de <https://www.who.int/dietphysicalactivity/pa/es/>
- mundial de la salud, O. (2019b). *Inactividad física: un problema de salud pública mundial*. Descargado 2019-07-16, de https://www.who.int/dietphysicalactivity/factsheet_inactivity/es/
- Orellana, P., Ramírez, M., Barceló, A., y Gil, E. (2006). Organización panamericana de la salud iniciativa centroamericana de diabetes (camdi): encuesta de diabetes, hipertensión y factores de riesgo de enfermedades crónicas. *Villa Nueva, Guatemala*.
- Paliyawan, P., Nukoolkit, C., y Mongkolnam, P. (2014). Prolonged sitting detection for office workers syndrome prevention using kinect. En *2014 11th international conference on electrical engineering/electronics, computer, telecommunications and information technology (ecti-con)* (pp. 1–6).
- Pisharady, P. K., y Saerbeck, M. (2013). Kinect based body posture detection and recognition system. En *International conference on graphic and image processing (icgip 2012)* (Vol. 8768, p. 87687F).
- Shum, H., y Ho, E. S. (2012). Real-time physical modelling of character movements with microsoft kinect. En *Proceedings of the 18th acm symposium on virtual reality software and technology* (pp. 17–24).
- Shum, H. P., Ho, E. S., Jiang, Y., y Takagi, S. (2013). Real-time posture reconstruction for microsoft kinect. *IEEE transactions on cybernetics*, 43(5), 1357–1369.
- Shum, H. P., Komura, T., y Takagi, S. (2011). Fast accelerometer-based motion recognition with a dual buffer framework. *The International Journal of Virtual Reality*, 10(3), 17–24.
- withfit. (2019). *Air squat*. Descargado 2019-07-16, de <http://www.withfit.com/exercises/Air+Squat>